Bienvenidos a la Matería

Herramientas y Técnicas Avanzadas para Ciencia de Datos

Profesor: Miguel Ángel Galindo Pérez de León

Grupo 702 Horario:
lunes y jueves 15:00 a 17:00

Código de clase 7r5w5u44

NORMATIVIDAD DENTRO Y FUERA DEL SALÓN DE CLASE

1. No podrá ingresar Alimentos y líquidos al laboratorio o salón
2. Tendrán una tolerancia de 5 minutos después de la Hora de clases
3. Podrán ingresar a la siguiente hora siempre y cuando ingrese antes de los 5 minutos después de la hora
4. El alumno se conducirá con respeto al profesor
5. El profesor se conducirá con respeto al alumno
6. Al término de la clase el alumno deberá de apagar su equipo de cómputo y colocar en orden su silla, teclado y ratón
7. Podrá consultar su dispositivo móvil pero no podrá estar chateando en redes sociales o consultado
8. Deberá de traer una USB para el resguardo de su actividad
9. Queda prohibido guardar su archivo o sus prácticas en el equipo de computo
10. Guardar respeto a sus compañeros y docente
11. Trabajar en equipo para cumplir con los objetivos deseados
12. Como mínimo 80% asistencia, derecho de exámenes
13. Si tiene 20 % o menos de faltas, será de baja en la materia
14. Si la asistencia de una clase es menora al 50% se aplicará examen correspondiente “parcial” o “Final”

CIENCIAS DE DATOS PARA NEGOCIOS

Objetivo de la materia:

Se busca trascender los fundamentos del machine learning para explorar algoritmos y frameworks de vanguardia. El curso pretende enseñar a resolver problemas complejos de datos que requieren soluciones no triviales y altamente optimizadas. Un propósito clave es dominar las técnicas de aprendizaje profundo para aplicaciones como visión artificial y procesamiento de lenguaje.
También se enfoca en entender e implementar modelos generativos para la creación de datos sintéticos.
Otro objetivo vital es desarrollar competencias en el despliegue y mantenimiento de modelos mediante prácticas de MLOps.
La materia busca familiarizar al alumno con las plataformas de computación en la nube para escalar proyectos eficientemente. Se enseña a aplicar métodos de aprendizaje no supervisado para descubrir patrones ocultos en datos sin etiquetar.
Un fin importante es dominar el uso de algoritmos de ensemble como XGBoost para maximizar el rendimiento predictivo.
El curso tiene la meta de instruir en el uso de herramientas distribuidas como Apache Spark para big data.
Se procura que el estudiante comprenda los principios de la replicabilidad artificial para crear modelos confiables y éticos.
Otro objetivo es desarrollar la habilidad de realizar ingeniería de características avanzada para alimentar modelos complejos. La materia intenta brindar experiencia en el fine-tuning y adaptación de modelos preen trenados mediante transfer learning.
Se busca capacitar para el análisis avanzado de series de tiempo usando modelos estadísticos y de deep learning.
El curso pretende introducir los conceptos del aprendizaje por refuerzo para problemas de decisión secuencial. Un objetivo crucial es aprender a evaluar, comparar y seleccionar la técnica más adecuada para cada problema. Finalmente, la materia aspira a integrar todas estas herramientas en un flujo de trabajo profesional y robusto.
El fin último es formar científicos de datos que puedan innovar y liderar proyectos avanzados en la industria.

CIENCIAS DE DATOS PARA NEGOCIOS

- Big Data y ciencia de datos
- Las características de Big Data
- Arquitectura centralizadas y distribuida
- Datos en reposo y movimientos
- Arquitectura Z y Lambda





Introducción a los grandes volúmenes de datos



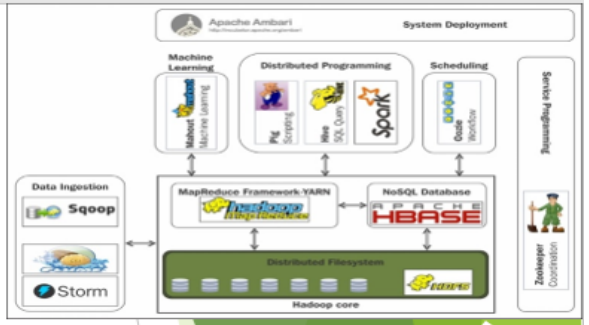




- Operadores, paquetes y funcione.
- Funciones y Anónimas
- Panda, Numpy, Parquet
- Anaconda
- Flask

Python para Big Data





Hadoop para lagos de datos

- HDFS
- Mapreduce
- Apache YARN
- Apache Sqoop
- Apache Zookeper
- Mesos



Problema Prototípico
Herramientas para la Gestión de Grandes Volúmenes de Datos

Procesamiento de grandes volúmenes en reposo

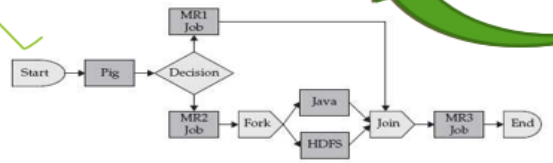
- Apache Pig
- Apache Hive
- Apache Hbase
- Apache Cassandra
- Apache SparkSQL

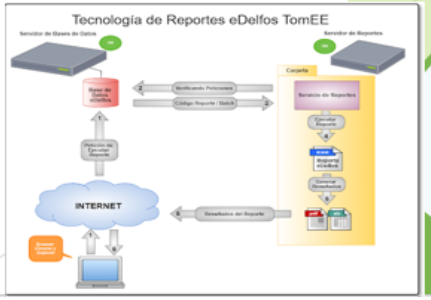




Procesamiento de grandes volúmenes en movimientos

- Arquitectura Lambda
- Apache Kafka
- Apache Flume
- Apache SparkStreaming
- Apache SparkGraphX





Temario:

T1- Grandes volúmenes de datos en reposo y movimiento

- 1.1 Fundamentos de analítica de Big Data.
- 1.2 Datos en reposo y en movimiento.
- 1.3 Almacenamiento de grandes datos.
- 1.4 procesamiento de grandes datos.
- 1.5 Visualización de grandes datos.

T2- Herramientas para procesamiento de grandes volúmenes de datos en reposo

- 2.1 Apache Ping
- 2.2 Apache Hive
- 2.3 Apache Hbase
- 2.4 Apache Cassandra.
- 2.5 Apache SparkSQL.

Temario:

T3- Herramientas para procesamiento de grandes volúmen datos en movimiento

- 3.1 Arquitectura Lambda.
- 3.2 Apache Kafka.
- 3.3 Apache flume.
- 3.4 Apache SparkStreaming.
- 3.5 Apache SparkGraphs.

T4- Herramientas avanzadas para Big Data

4.1 Apache Mahout.
4.2 Dryad.
4.3 Storm y Apache Drill.
4.4 Jaspersoft y Splunk.

Temario:

T5- Julia para Ciencia de Datos

5.1 Descripción del lenguaje julia.
5.2 Constructores, comandos, funciones y librerías.
5.3 Explorando lagos de datos.
5.4 Métodologia de muestreo de dato y técnicas de evaluación de modelos.
5.5 Móldelo de aprendizaje supervisado y no supervisado.
5.6 Aplicaciones en análisis de Big Data de alto rendimiento.

Temario:

T6- TensorFlow y Big Data

6.1 Algebra lineal para Analítica predictiva.
6.2 Estadística y Probabilidad para modelación predictiva.
6.3 De datos a decisiones.
6.4 Aprendizaje supervisado para analítica predictiva.
6.5 Redes Neuronales Profundas para análisis predictivo.

Bibliografía:

- Müller, A. C., & Guido, S. (2018). Introducción al machine learning con Python: Una guía para científicos de datos. Editorial O'Reilly.
- Géron, A. (2021). Aprendizaje profundo con Python y TensorFlow (2a ed.). Marcombo.
- Rojas, E., & Medina, S. (2020). Ciencia de datos con Python: Las mejores herramientas para el análisis de datos. Alfaomega.
- Villegas, M. (2019). Minería de datos: Técnicas y herramientas (2a ed.). Grupo Editorial Patria.
- Chollet, F. (2022). Deep Learning con Python (2a ed.). Manning Publications.

Evaluación:

Evaluación continua activa en clase	10 %
Evaluació plataforma	10 %
Examen parcial	30 %
Examen Final	30 %
Proyecto prototípico	30 %
Total =	100 %