UNIVERSIDAD NACIONAL ROSARIO CASTELLANOS

Licenciatura en Ciencia de Datos para Negocios

Manual del Estudiante
Seminario de Titulación I

Guía Práctica y Metodológica (Séptimo Semestre)

AUTORES

Mtro. David Isaac Camargo Manriquez

Dr. Mario Hugo Cuéllar Meléndez

Ciudad de México, 2026

PRESENTACIÓN

Bienvenida al Seminario

Estimados estudiantes de séptimo semestre:

Es un honor darles la más cordial bienvenida al Seminario de Titulación I de la Licenciatura en Ciencia de Datos para Negocios de la Universidad Nacional Rosario Castellanos. Llegar a esta etapa representa el inicio de su consolidación como profesionales capaces de transformar su entorno a través del rigor científico y la innovación tecnológica.

A lo largo de su formación, han construido un sólido cimiento técnico dominando el "cómo" de la ciencia de datos mediante programación, estadística y el entrenamiento de modelos de aprendizaje automático. Sin embargo, este seminario marca un punto de inflexión metodológico y cognitivo: es el momento de dominar el "qué" y el "por qué". El mercado actual exige estrategas analíticos con la madurez necesaria para identificar anomalías en los procesos de negocio, diseñar metodologías rigurosas y proponer soluciones de alto impacto social y económico.

Este manual ha sido diseñado para acompañarlos paso a paso en la transición de alumnos a investigadores. A través del análisis reflexivo de incidentes críticos y el trabajo colaborativo, desarrollarán el anteproyecto que servirá como pilar de su titulación. Los exhortamos a aprovechar al máximo cada sesión, a cuestionar con ética y a estructurar sólidamente sus ideas. Su trabajo recepcional es, a partir de hoy, su carta de presentación ante el mundo profesional.

Les deseamos el mayor de los éxitos en esta etapa.

Mtro. David Isaac Camargo Manriquez

Dr. Mario Hugo Cuéllar Meléndez

ÍNDICE DE CONTENIDOS

Presentación Bienvenida al Seminario **2**

BLOQUE A: Responsabilidad social universitaria e investigación

Sesión 1 Encuadre y Presentación del Manual de Titulación **4**

Sesión 2 El Científico de Datos frente a la Sociedad **6**

Sesión 3 Rutas de Investigación y Titulación **8**

BLOQUE B: Elementos de encuadre de un anteproyecto

Sesión 4 De la Idea de Negocio al Problema de Investigación **10**

Sesión 5 El Arte de Problematizar con Datos **12**

Sesión 6 Justificación y Viabilidad del Proyecto **14**

Sesión 7 Formulación de Supuestos e Hipótesis **16**

Sesión 8 Trazando la Ruta: Objetivos y Preguntas **18**

BLOQUE C: Elementos metodológicos para el desarrollo

Sesión 9 Paradigmas Metodológicos en la Ciencia de Datos **20**

Sesión 10 Técnicas de Recolección de Información **22**

Sesión 11 Fundamentación Teórica y Aparato Crítico **24**

Sesión 12 Planeación y Tiempos de Ejecución **26**

BLOQUE D: Presentación del anteproyecto

Sesión 13 Diseño de Presentaciones de Alto Impacto **28**

Sesión 14 Taller de Revisión y Ajuste Documental **30**

Sesión 15 Comunicación de Resultados **32**

Sesión 16 Defensa del Anteproyecto **34**

Bibliografía

Anexo Bibliografía Básica y de Consulta **35**

SESIÓN 1

Encuadre y Presentación del Manual de Titulación

TEMA A TRATAR

Esta primera sesión constituye el pilar fundacional del Seminario de Titulación I. No se trata únicamente de un acto administrativo de lectura de un temario, sino del punto de inflexión en la trayectoria del estudiante: el tránsito definitivo de la asimilación pasiva de conocimientos técnicos hacia la generación activa de propuestas de investigación aplicada en el campo de la Ciencia de Datos para Negocios.

El Enfoque Pedagógico

Para comprender la magnitud de este seminario, es imperativo adentrarse en el modelo educativo que lo sustenta, el cual se apoya fuertemente en las directrices del aprendizaje activo y la resolución de problemas anclados en la realidad. Siguiendo el marco educativo delineado por figuras como la Dra. Alma Herrera, el proceso formativo exige que el alumno se enfrente a la complejidad del entorno profesional no mediante simulaciones estériles, sino a través del análisis de *incidentes críticos*. Un incidente crítico no es un simple ejercicio de programación; es una fractura en la cotidianidad de una organización, una situación donde los datos revelan una disonancia, un sesgo, o una oportunidad de innovación social y económica que demanda una intervención estructurada.

Transición a la Investigación

A lo largo de seis semestres, el enfoque ha recaído en dominar lenguajes de programación, comprender la estadística inferencial y desplegar modelos algorítmicos. Sin embargo, en el séptimo semestre, la técnica por sí sola resulta insuficiente. El mercado y la academia requieren estrategas. En este encuadre, se establece el acuerdo fundamental del curso: el estudiante deberá asumir la postura de un investigador. Esto implica dudar de las premisas dadas,

cuestionar la calidad y el origen de los datos, y estructurar una metodología rigurosa antes de escribir una sola línea de código.

Criterios de Evaluación y Herramientas

El encuadre detalla la evaluación continua, diseñada no para penalizar, sino para guiar la maduración del anteproyecto. El 10% corresponde al ensayo crítico (demostración de pensamiento complejo), un 35% se divide en las entregas parciales del esbozo del anteproyecto, un 15% a la síntesis audiovisual y un 30% a la defensa final. Además, se fomenta la adopción ética de herramientas de inteligencia artificial generativa. Plataformas como NotebookLM y entornos de gestión como Google Classroom no reemplazan el juicio crítico del alumno; por el contrario, actúan como andamiajes cognitivos para organizar la vasta literatura académica y optimizar los tiempos de gestión documental, permitiendo al estudiante centrar su esfuerzo cognitivo en la problematización real.

LECTURA INTRODUCTORIA

La investigación formal frente a los retos laborales del Científico de Datos

En el vertiginoso mundo de la Ciencia de Datos para Negocios, donde las herramientas, arquitecturas en la nube y librerías de *Machine Learning* cambian semestralmente, surge una pregunta recurrente entre los estudiantes de últimos semestres: **¿Por qué invertir tiempo y esfuerzo en una investigación académica formal?**

La respuesta radica en el desarrollo del *pensamiento estructurado y complejo*. Mientras que el mercado laboral exige, en un primer nivel, la resolución técnica y rápida de problemas mediante la ejecución de algoritmos, la academia forja la capacidad crítica de **problematizar**. Un científico de datos que únicamente sabe ejecutar código dictado por un superior se limita a un rol técnico; en contraste, un profesional que sabe contextualizar un fenómeno de negocio, justificar su relevancia social, formular preguntas precisas, plantear hipótesis sólidas y estructurar una metodología rigurosa, se convierte en un estratega analítico.

INSTRUCCIONES PARA EL EJERCICIO

1. **Análisis y Apropiación del Programa:**

   Abran el documento oficial del programa ("TRANSVERSAL_7_8_SEMINARIO DE TITULACIÓN I_FINAL.pdf"). Ubiquen la tabla de ponderaciones y analicen los porcentajes de cada entregable. Abran un documento en su procesador de textos y anoten las fechas límite estimadas para los 5 entregables principales de acuerdo con el calendario proporcionado en clase.

2. **Firma de Acuerdos y Política Anti-Plagio:**

   Descarguen la "Carta de Compromiso" desde la plataforma. Lean detenidamente la sección sobre el uso ético de la Inteligencia Artificial (diferenciando entre su uso como herramienta de apoyo y el plagio algorítmico). Firmen el documento (de forma digital o física escaneada) y súbanlo al repositorio designado bajo el formato de nombre *Apellidos_Nombre_Carta.pdf*.

3. **Configuración del Entorno de Trabajo:**

   Ingresen a Google Classroom con su cuenta de correo institucional. Matricúlense en la clase usando el código proporcionado por el docente. A continuación, creen una carpeta en su Google Drive institucional nombrada *Seminario_Titulacion_I_SusApellidos* y compartan el enlace de edición con el profesor; esta carpeta servirá como portafolio de evidencias.

SESIÓN 2

El Científico de Datos frente a la Sociedad

TEMA A TRATAR

La formación de un Científico de Datos para Negocios en la Universidad Nacional Rosario Castellanos no concibe a la tecnología como un fin en sí mismo, sino como un habilitador para el desarrollo y el bienestar. Por ello, esta sesión se sumerge profundamente en el concepto de la Responsabilidad Social Universitaria (RSU). La RSU trasciende el asistencialismo o la ética superficial; se trata de una política de gestión de la calidad ética de la universidad, donde el conocimiento generado en las aulas debe tener un impacto demostrable y positivo en la resolución de las asimetrías de la sociedad.

El Pensamiento Lineal vs. Pensamiento Complejo

Para lograr este impacto, el estudiante debe confrontar y superar el paradigma del *pensamiento lineal*. Históricamente, la ciencia se ha basado en la fragmentación de los problemas: aislar variables, buscar relaciones directas de causa y efecto, y maximizar una métrica específica (como el margen de error de un modelo estadístico). Este enfoque, si bien útil en entornos controlados, fracasa estrepitosamente cuando se aplica a fenómenos sociales o empresariales reales. El pensamiento lineal en la ciencia de datos asume que "los datos hablan por sí mismos", ignorando que la recolección, selección y limpieza de datos son actos humanos cargados de sesgos.

Frente a esto, se postula el *pensamiento complejo*. Inspirado en teóricos como Edgar Morin, el pensamiento complejo reconoce que los fenómenos están interconectados y son multidimensionales. Un algoritmo que decide a quién otorgar un crédito no es solo una ecuación matemática; es un instrumento que interactúa con la economía, la sociología, el derecho y la historia de una comunidad. El científico de datos formado bajo esta visión entiende que modificar una variable en un sistema altera el todo, y que los modelos algorítmicos pueden amplificar desigualdades sistémicas si no son diseñados con una mirada crítica y humanista.

Aplicación en el Anteproyecto

El objetivo de esta sesión es que el alumno internalice que su tema de investigación no flota en un éter académico. Ya sea que elija optimizar la logística de una cadena de suministro, mejorar la predicción de ventas de una Pyme, o analizar tendencias de salud pública mediante datos, su trabajo debe justificar explícitamente su contribución. Debe responder a la pregunta fundamental: ¿Cómo el conocimiento técnico que voy a desplegar mejora, aunque sea a microescala, las condiciones de mi entorno?

ESTUDIO DE CASO (INCIDENTE CRÍTICO)

El Algoritmo "Ciego": Cuando la precisión técnica ignora la realidad social

En 2023, una reconocida institución financiera implementó un modelo de *Machine Learning* para automatizar la aprobación de líneas de crédito. El equipo, enfocado en el **pensamiento lineal** para optimizar el *accuracy*, alimentó la red neuronal con décadas de datos históricos. Aparentemente, el proyecto fue un éxito al reducir los tiempos de aprobación en un 80%.

A los seis meses, una auditoría reveló que el algoritmo denegaba sistemáticamente créditos a solicitantes de zonas periféricas. Al carecer de **pensamiento complejo**, los desarrolladores no notaron que los datos históricos contenían un sesgo estructural heredado de políticas de exclusión financiera del pasado. El modelo automatizó la discriminación.

INSTRUCCIONES PARA EL EJERCICIO

1. **Debate Guiado (Foro de Discusión):**

   Tras la lectura del incidente crítico del "Algoritmo Ciego", reúnanse en equipos de tres personas. Analicen el caso y respondan grupalmente a la siguiente pregunta: *Si ustedes fueran los auditores de ese banco, ¿qué tres métricas (fuera del aspecto puramente matemático, es decir, métricas sociales o éticas) hubieran exigido monitorear antes del despliegue del modelo?* Nombren a un portavoz para compartir sus conclusiones en plenaria.

2. **Lluvia de Ideas (Estructuración del Ensayo):**

   De forma individual, abran un documento nuevo. Escriban en el centro de la página la palabra "Responsabilidad". Ramifiquen tres ideas o argumentos principales sobre cómo los modelos de datos afectan a poblaciones vulnerables o dinámicas empresariales. Estas tres ramas se convertirán en los tres párrafos de desarrollo de su próximo *Ensayo Crítico*.

3. **Identificación de Impacto (Entregable Preliminar):**

   Redacten un párrafo de máximo 150 palabras titulado "Mi Impacto Social". Describan de manera directa y concreta cómo el tema que les interesa investigar para su titulación podría mejorar un proceso, reducir un sesgo o aportar valor a un sector específico de la sociedad. Suban este breve texto a la tarea asignada en Classroom.

SESIÓN 3

Rutas de Investigación y Titulación

TEMA A TRATAR

Una vez que el estudiante ha comprendido su responsabilidad social y el enfoque complejo de su disciplina, es el momento de formalizar el vehículo a través del cual presentará su investigación. Esta sesión está dedicada a desmitificar el proceso de titulación y a trazar un mapa claro de las modalidades oficialmente reconocidas por la normatividad de la Universidad.

La Normativa Institucional: Más allá del Semestre

Un aspecto de vital importancia que debe quedar meridianamente claro en esta sesión es el deslinde entre las actividades evaluativas semestrales y el proceso oficial de obtención de grado. Durante su formación, los alumnos han trabajado exhaustivamente mediante la metodología de resolución de problemas prototípicos, una excelente herramienta pedagógica. Sin embargo, **es una directriz institucional inamovible que los estudiantes no se titulan por problemas prototípicos**. El problema prototípico es un ensayo formativo; la titulación exige la culminación de un documento recepcional exhaustivo, estructurado y defendido ante un sínodo.

Anatomía de las Modalidades de Titulación

Para la Licenciatura en Ciencia de Datos para Negocios, se exponen las siguientes vías metodológicas, cada una con un propósito y alcance distinto:

1. La Tesis: Es la reina de la investigación formal. Se caracteriza por la formulación de una hipótesis original que debe ser comprobada o refutada mediante la experimentación, el análisis de datos riguroso y la argumentación científica. Es ideal para estudiantes que desean profundizar en arquitecturas de algoritmos, proponer nuevas métricas o adentrarse en la academia y los posgrados.

2. La Tesina: A diferencia de la tesis, la tesina es un trabajo monográfico que no exige necesariamente la comprobación de una hipótesis empírica inédita, sino que requiere una

profunda revisión del estado del arte, una compilación exhaustiva de marcos teóricos o el análisis documental de un fenómeno específico dentro de la ciencia de datos (por ejemplo, marcos regulatorios de la Inteligencia Artificial).

3. El Informe o Proyecto Profesional: Esta es, estadísticamente, la ruta más afín al perfil del científico de datos aplicado. Consiste en la documentación sistemática de una intervención real en una organización. El estudiante diagnostica un problema de negocio, diseña una solución basada en datos (un dashboard, un modelo predictivo, una reestructuración de bases de datos), la implementa y evalúa críticamente los resultados obtenidos. Requiere un marco metodológico sólido, pero su enfoque es la resolución de problemas en campo.

El estudiante deberá salir de esta sesión con una claridad absoluta sobre cuál de estos trajes a la medida se ajusta mejor a la investigación que está a punto de emprender.

LECTURA INTRODUCTORIA

Tres Caminos hacia la Titulación: De la ejecución a la investigación

Elegir la modalidad de titulación es la primera gran decisión estratégica. Ana decide elaborar una **Tesis** para demostrar una nueva hipótesis sobre la eficiencia de redes neuronales en el sector salud. Carlos opta por un **Informe o Proyecto**, ya que implementará un modelo de segmentación de clientes en una Pyme real y documentará rigurosamente el proceso. Luis elige la **Tesina**, realizando un trabajo monográfico extenso sobre el estado del arte de la privacidad de datos.

Independientemente del camino elegido, todos requieren de un anteproyecto sólidamente investigado, recordando que la academia exige que la práctica profesional esté sustentada en metodologías formales y documentos recepcionales avalados, dejando atrás la etapa de los projects puramente de clase.

INSTRUCCIONES PARA EL EJERCICIO

1. **Construcción de la Matriz de Decisión:**

   En una hoja de cálculo o documento, tracen una tabla con tres columnas correspondientes a las modalidades: Tesis, Tesina, Informe/Proyecto. Para cada columna, evalúen su nivel de afinidad (Alto, Medio, Bajo) respondiendo a estas tres preguntas clave: *a) ¿Quiero comprobar una hipótesis metodológica nueva mediante codificación compleja?, b) ¿Prefiero analizar a profundidad bibliografía y marcos regulatorios existentes?, c) ¿Tengo acceso garantizado a los datos de una empresa real para resolverles un problema práctico y medible?*

2. **Redacción de la Selección Preliminar:**

   Basándose en los resultados de su matriz, redacten una justificación argumentativa (media cuartilla) que contenga la siguiente estructura:
   - Párrafo 1: "La modalidad de titulación seleccionada para mi desarrollo profesional es [Modalidad]".
   - Párrafo 2: "Esta elección se justifica metodológicamente porque mi interés se orienta hacia [Área de datos], y el trabajo requiere [justificar por qué esa modalidad es idónea para los datos que manejarán]".
   - Párrafo 3: "Reconozco institucionalmente que el diseño de este anteproyecto se evaluará bajo el rigor de la modalidad elegida, independientemente de los problemas prototípicos abordados en mi trayectoria previa".

3. **Retroalimentación de la Elección:**

   Envíen su selección preliminar al foro de la clase. Cada alumno deberá comentar la selección de al menos un compañero, indicando si los argumentos presentados justifican sólidamente la viabilidad del proyecto propuesto.

SESIÓN 4

De la Idea de Negocio al Problema de Investigación

TEMA A TRATAR

El obstáculo cognitivo más grande al iniciar un trabajo recepcional es la confusión epistemológica entre un "Tema" y un "Problema". Esta sesión está dedicada íntegramente a desarmar esta confusión, proporcionando a los alumnos las herramientas analíticas para transitar de la fascinación por una tecnología hacia la identificación de una verdadera brecha de investigación.

El Tema: El Universo General

Un tema de investigación es una categoría amplia, un área de interés general. Ejemplos comunes en esta licenciatura incluyen: "Big Data en el sector farmacéutico", "Inteligencia Artificial Generativa en Marketing" o "Sistemas de Recomendación". El tema es estático; es un sustantivo. Si un estudiante afirma que su investigación "es sobre Big Data", aún no tiene una investigación; tiene simplemente un área de interés documental. El tema no exige acción, no plantea dudas; simplemente existe.

El Problema: La Fricción en la Realidad

Por el contrario, un problema de investigación es una anomalía, un vacío de conocimiento, una disfunción en un proceso de negocio o una contradicción entre la teoría y la práctica que demanda una explicación o solución. El problema es dinámico y conflictivo. Transitar del tema al problema implica agregar variables de espacio, tiempo, sujetos de estudio y, sobre todo, una fricción.

Tomando el tema "Big Data en el sector farmacéutico", la evolución hacia un problema de investigación se vería así: *"La incapacidad de las farmacias independientes en la alcaldía Gustavo A. Madero (espacio) para predecir la demanda de medicamentos estacionales (fricción)*

durante el año 2025 (tiempo), debido a la falta de estructuración de sus históricos de ventas, lo que genera un 20% de pérdida por caducidad (magnitud del problema)".

El Papel de la Inteligencia Artificial en la Delimitación

Para facilitar este proceso de embudo (de lo general a lo particular), se instruirá a los estudiantes en el uso avanzado de modelos de lenguaje y herramientas de síntesis (como NotebookLM) como asistentes de investigación. Estas herramientas no definirán el problema por el alumno, pero son excepcionalmente útiles para mapear el estado del arte, identificar qué subtemas ya están saturados de investigación y encontrar esos "nichos" o lagunas donde el estudiante puede insertar su propuesta de valor. Se enseñará a formular los *prompts* correctos para iterar sobre una idea vaga hasta convertirla en un enunciado de problema filoso y directo.

ESTUDIO DE CASO

El Espejismo Tecnológico: Cuando el "Tema" oculta al "Problema"

Una cadena de supermercados contrató a una consultora con la directiva: "Queremos implementar Inteligencia Artificial para predecir inventarios". Los consultores, fascinados con el "tema", desarrollaron un complejo modelo de Deep Learning.

Al implementarlo, los resultados fueron nulos. ¿La razón? Nunca definieron el verdadero "problema". La falta de inventario no se debía a una mala predicción, sino a cuellos de botella logísticos locales y a la mala captura manual de mermas por parte de los empleados. La IA predecía perfectamente sobre procesos rotos.

Plantear correctamente el problema real (el origen de la discrepancia de datos logísticos) habría evitado un fracaso millonario. Plantear el problema es el 80% de la solución.

INSTRUCCIONES PARA EL EJERCICIO

1. **Delimitación Asistida del Tema (Uso de IA):**

   Ingresen a NotebookLM (o a la herramienta de IA sugerida por el docente). Suban 3 artículos académicos recientes sobre su área tecnológica de interés. Escriban el siguiente prompt para iniciar la iteración: *"Actúa como un experto en metodología de la investigación. Basado estrictamente en estos documentos, mi tema general de interés es [Insertar Tema]. Sugiéreme 3 preguntas de investigación específicas, acotadas y viables orientadas a los negocios, que no estén completamente resueltas en los textos y que presenten un vacío analítico."*

2. **Selección y Filtrado del Problema:**

   De las sugerencias arrojadas, elijan la que represente un desafío factible de investigar con los datos a los que tienen acceso real. Escríbanla en la parte superior de su documento de trabajo.

3. **Construcción del Diagrama de Embudo:**

   En una diapositiva o en una hoja, dibujen un triángulo invertido (embudo) estructurado en cuatro niveles jerárquicos:

   - Nivel 1 (Superior/Ancho): Escriban el *Tema Macro* (Ej. Machine Learning en Retail).
   - Nivel 2 (Medio-Alto): Definan la *Fricción o Necesidad* (Ej. Alta tasa de merma en productos perecederos).
   - Nivel 3 (Medio-Bajo): Definan el *Sujeto y Espacio* (Ej. Pymes abarroteras locales en CDMX).
   - Nivel 4 (Punta/Estrecho): Escriban la *Temporalidad* (Ej. Comportamiento en el último semestre de 2025).

4. **Enunciado Final:**

   Redacten en un solo párrafo claro y articulado la conjunción de los 4 niveles del embudo. Este párrafo será el "Enunciado del Problema" oficial de su anteproyecto.

SESIÓN 5

El Arte de Problematizar con Datos

TEMA A TRATAR

Tener un problema delimitado es el primer paso, pero construir el pilar fundamental del anteproyecto requiere *problematizarlo*. La problematización es el andamiaje retórico y metodológico que convence al lector (y al jurado) de que la investigación es no solo viable, sino absolutamente necesaria. En esta sesión, diseccionaremos la metodología de la problematización estructurada en cuatro ejes cardinales, una técnica que asegura que el estudiante argumente con la solidez requerida en el ámbito de la ciencia de datos y los negocios.

1. Historizar

Un problema de datos rara vez surge de la noche a la mañana; es el resultado de un proceso. Historizar significa trazar la línea de tiempo del fenómeno. Si el problema es la "alta tasa de abandono de clientes en una plataforma e-commerce", el alumno debe investigar cuándo comenzó el pico de abandonos, qué factores tecnológicos o del mercado cambiaron en ese periodo, y cómo se ha comportado la curva de datos a lo largo del último trienio. Historizar da peso y contexto evolutivo al fenómeno.

2. Contextualizar

Ningún modelo algorítmico flota en el vacío. Contextualizar implica enmarcar el problema geográficamente, económicamente y organizacionalmente. Se debe describir la naturaleza de la empresa o sector afectado, las limitaciones de infraestructura tecnológica actuales (¿tienen servidores on-premise, usan la nube, manejan datos estructurados o no estructurados?), y las normativas que los rigen. El contexto delimita el alcance de lo que es posible investigar e implementar.

3. Conceptualizar

Este es el puente entre la práctica de negocios y la academia. Conceptualizar obliga al estudiante a utilizar el lenguaje técnico y las teorías validadas de su disciplina para explicar el problema. No se dice "la gente se va porque la página es lenta"; se conceptualiza como "existe una fricción en la experiencia de usuario (UX) que impacta directamente en la tasa de conversión (Conversion Rate) dentro del embudo de ventas digital". Aquí se introducen los marcos teóricos preliminares y los conceptos clave de la ciencia de datos que orbitan la problemática.

4. Caracterizar

La característica suprema del Científico de Datos: si no se puede medir, no existe. Caracterizar el problema significa ponerle números, porcentajes y dimensiones a la fricción. ¿De cuánto dinero estamos hablando en pérdidas? ¿Qué volumen de datos se está desperdiciando? ¿Cuál es la latencia actual del sistema? Caracterizar proporciona la "línea base" (baseline) contra la cual se medirá el éxito de la propuesta o de la hipótesis al final de la investigación.

El dominio de estos cuatro ejes a través del análisis riguroso de incidentes críticos transforma una simple queja empresarial en un anteproyecto académico robusto y blindado ante el escrutinio de cualquier sínodo.

ESTUDIO DE CASO (INCIDENTE CRÍTICO)

Gobernanza de Datos en Cooperativas Agrícolas

Una cooperativa de riego sufría pérdidas de cultivos por mala gestión del agua. El científico de datos asignado no se limitó a proponer un modelo estadístico, sino que **problematizó** la situación:

1. **Historizar:** Investigó que el problema comenzó hace cinco años, con el cambio de regulaciones y un monocultivo intensivo adyacente.
2. **Contextualizar:** Definió que la cooperativa operaba con decisiones asamblearias donde los datos meteorológicos llegaban con tres días de retraso, sin red digital local.
3. **Conceptualizar:** Enmarcó el escenario bajo la "Gobernanza de Datos Descentralizada" y "Sistemas de Riego de Precisión".
4. **Caracterizar:** Midió el problema: pérdida del 22% del rendimiento anual debido a datos fragmentados en hojas de cálculo inconexas.

Al problematizar así el incidente, el objetivo se volvió claro: "diseñar un esquema de gobernanza de datos agrometeorológicos para optimizar decisiones".

INSTRUCCIONES PARA EL EJERCICIO

1. **Redacción de la Problematización (Borrador Inicial):**

   Tomando como base el enunciado del problema generado en la Sesión 4, abran su procesador de textos y redacten cuatro párrafos descriptivos y académicos, uno para cada eje. Sigan esta estructura exacta:

   - *Párrafo 1 (Historizar):* Expliquen el origen cronológico de la fricción (¿Desde cuándo existe?).

   - *Párrafo 2 (Contextualizar):* Describan el entorno (¿Dónde ocurre, qué tipo de negocio es y qué arquitectura de datos emplean actualmente?).

   - *Párrafo 3 (Conceptualizar):* Nombren y relacionen al menos tres conceptos técnicos o teóricos de la Ciencia de Datos que apliquen al fenómeno (ej. Calidad del Dato, ETL, Modelos de Clasificación).

   - *Párrafo 4 (Caracterizar):* Escriban al menos dos métricas, estimadas o reales, que midan la gravedad actual del problema.

2. **Taller de Revisión Cruzada (Coevaluación):**

   Durante la clase, intercambien su documento con un compañero. El revisor utilizará la herramienta de subrayado (física o digital) aplicando este código de colores: subraye en *Amarillo* si falta precisión en el contexto espacial/temporal; en *Verde* si los conceptos técnicos son claros y apropiados; y en *Rojo* si el texto carece de métricas comprobables en el párrafo de caracterización.

3. **Ajuste y Consolidación:**

   Corrijan su texto basándose estrictamente en la retroalimentación de su compañero. El documento pulido se subirá al sistema como la primera versión oficial del apartado "Problematización" de su Anteproyecto.

SESIÓN 6

Justificación y Viabilidad del Proyecto

TEMA A TRATAR

Una vez que el problema ha sido delimitado y problematizado, el siguiente paso metodológico es defender por qué vale la pena resolverlo. Esta sesión se enfoca en la **Justificación** y la **Viabilidad**, dos elementos críticos que determinan si un anteproyecto es aprobado por la academia o rechazado por falta de sustento o realismo.

La Justificación: Las Tres Dimensiones

Justificar no es repetir el problema, es argumentar sus beneficios y su relevancia. Un proyecto de titulación en esta universidad debe justificarse obligatoriamente bajo tres dimensiones:

1. Dimensión Social: ¿Cómo impacta esta investigación a la comunidad? Incluso si el proyecto es para optimizar ganancias en una empresa privada, el estudiante debe articular cómo la retención de empleos, la mejora en el servicio al consumidor o la reducción de huella de carbono aportan a la sociedad.

2. Dimensión Académica: ¿Qué aporta este trabajo al cuerpo de conocimiento de la Licenciatura en Ciencia de Datos para Negocios? Puede ser la validación de un algoritmo en un entorno no explorado previamente, o la integración de marcos teóricos que enriquecen la literatura disponible.

3. Dimensión Profesional: ¿Cómo beneficia esta investigación al estudiante como futuro egresado y a la industria en general? Aquí se argumenta la aplicabilidad práctica de las habilidades técnicas adquiridas.

La Viabilidad: El Filtro de la Realidad

La viabilidad es el análisis crudo de los recursos disponibles. Un proyecto puede tener una excelente justificación, pero carecer de viabilidad. En ciencia de datos, la viabilidad se sostiene sobre tres pilares: *a) Viabilidad de Datos* (¿Los datos existen, son accesibles, o están protegidos

por leyes de privacidad?), *b) Viabilidad Técnica* (¿Se cuenta con el poder computacional necesario para entrenar el modelo en el tiempo requerido?), y *c) Viabilidad Temporal* (¿Puede completarse el ciclo de investigación en el lapso de este semestre o del subsecuente?). Si alguna de estas respuestas es negativa, el problema debe ser replanteado.

ESTUDIO DE CASO (INCIDENTE CRÍTICO)

El Proyecto Perfecto que Nunca Nació

Un estudiante de ciencia de datos propuso un proyecto brillante: desarrollar una red neuronal convolucional para predecir enfermedades cardiovasculares raras a partir de historiales clínicos de hospitales públicos de la Ciudad de México. La **justificación social** era innegable y el **reto académico**, excepcional.

Sin embargo, el anteproyecto fue rechazado en la primera revisión por falta de **viabilidad**. El estudiante no consideró que el acceso a datos clínicos está estrictamente protegido por la Ley Federal de Protección de Datos Personales en Posesión de Sujetos Obligados. Tramitar los permisos de anonimización tomaría, según los cálculos legales, más de 18 meses, un plazo incompatible con su calendario de titulación. Este incidente subraya que en ciencia de datos, sin acceso legal y técnico a la materia prima (el dato), el proyecto es inviable, por más noble que sea su justificación.

INSTRUCCIONES PARA EL EJERCICIO

1. **Auditoría de Viabilidad (Checklist):**

   Abran un documento y respondan con "Sí" o "No" a las siguientes preguntas, justificando cada respuesta: 1. ¿Tengo el dataset en mis manos o el permiso firmado para obtenerlo? 2. ¿El dataset tiene los registros suficientes para entrenar mi modelo propuesto? 3. ¿Mi computadora (o la nube accesible) soporta la carga de procesamiento? Si tienen un "No", deben ajustar el alcance de su proyecto hoy mismo.

2. **Redacción de la Justificación:**

   Redacten tres párrafos robustos. Titulen el primero "Dimensión Social", el segundo "Dimensión Académica" y el tercero "Dimensión Profesional". Asegúrense de usar lenguaje persuasivo y técnico. Respondan claramente a la pregunta: ¿A quién beneficia directamente este desarrollo?

3. **Cierre y Entrega (Evaluación 10%):**

   Integren la justificación y la auditoría de viabilidad a su documento maestro de problematización (desarrollado en la sesión 5). A este documento integrado se le dará formato de *Ensayo Crítico*. Guárdenlo en formato PDF y súbanlo al espacio asignado en Google Classroom para recibir su primera evaluación sumativa del semestre (10% de la calificación final).

SESIÓN 7

Formulación de Supuestos e Hipótesis

TEMA A TRATAR

Una investigación no es una recolección de datos al azar esperando encontrar algo útil; es una brújula que apunta hacia una respuesta anticipada. Esta sesión marca la división entre los diferentes enfoques metodológicos al adentrarnos en el diseño de **Hipótesis** (para enfoques cuantitativos) y **Supuestos** (para enfoques cualitativos o exploratorios).

La Hipótesis: La Apuesta Cuantitativa

En el campo de la ciencia de datos para negocios, la gran mayoría de los proyectos son predictivos o prescriptivos, lo que requiere una hipótesis. Una hipótesis es una afirmación lógica y comprobable estadísticamente que relaciona dos o más variables. No es una pregunta, es una declaración. Estructuralmente, una hipótesis requiere una *Variable Independiente* (la causa o intervención tecnológica) y una *Variable Dependiente* (el efecto o impacto en el negocio).

Ejemplo incorrecto: *"¿Un algoritmo de Random Forest mejorará las ventas?"*
Ejemplo correcto: *"La implementación de un algoritmo de clasificación Random Forest (Variable Independiente) reducirá la tasa de abandono de clientes en un 15% (Variable Dependiente) en el próximo trimestre."* Esta estructura permite que, al final del proyecto, la hipótesis pueda ser rechazada o aceptada mediante métricas contundentes.

El Supuesto: La Exploración Cualitativa

Para aquellos trabajos enfocados en la arquitectura empresarial, marcos regulatorios (como una Tesina) o minería de textos exploratoria donde no se busca predecir sino comprender, se utilizan Supuestos. Un supuesto es una premisa inicial, cualitativa y razonable que guía la investigación sin someterse a una prueba de varianza estadística estricta. Ejemplo: *"La adopción de una cultura de alfabetización de datos (data literacy) en el personal de gerencia media facilita la transición hacia modelos de negocio basados en IA."*

ESTUDIO DE CASO (INCIDENTE CRÍTICO)

El Experimento A/B Fallido: El Peligro de una Mala Hipótesis

El equipo de *Growth Hacking* de una plataforma de comercio electrónico diseñó un experimento A/B costoso. Su hipótesis original fue: *"Cambiar el color del botón de pago a verde aumentará las ventas, porque el verde significa 'avanzar'."* Realizaron la prueba durante un mes y el resultado fue inconcluso; no hubo diferencias estadísticamente significativas.

El error radicó en la formulación de la hipótesis. Carecía de contexto de negocio y variables robustas. Tras una auditoría, el científico de datos reformuló la investigación con una hipótesis real: *"El despliegue de un modelo de recomendación de productos basado en el historial de navegación (Var. Independiente) aumentará el ticket promedio de compra en un 5% (Var. Dependiente) en la cohorte de usuarios recurrentes."* Esta nueva hipótesis sí era medible, apuntaba a un KPI específico del negocio (ticket promedio) y segmentaba correctamente los datos, lo que finalmente resultó en un experimento exitoso y accionable.

INSTRUCCIONES PARA EL EJERCICIO

1. **Taller de Identificación de Variables:**

   De manera individual, analicen su problema de investigación. Identifiquen claramente cuál será su intervención técnica (Variable Independiente, ej. Modelo de Regresión Logística, Dashboard en PowerBI) y qué métrica del negocio esperan alterar (Variable Dependiente, ej. Costo de adquisición, Tiempo de respuesta, Tasa de clasificación correcta). Anoten ambas variables.

2. **Redacción Formato Lógico:**

   Utilizando la fórmula condicional "Si [Variable Independiente] entonces [Variable Dependiente] dado que [Contexto]", redacten dos borradores de su hipótesis. Si su investigación es puramente documental/cualitativa, redacten dos supuestos lógicos.

3. **Validación por Criterio de Falsabilidad:**

   Intercambien su hipótesis con un compañero. El evaluador debe responder solo una pregunta: *"¿Existe una manera matemática o analítica de demostrar que esta hipótesis es falsa al terminar el proyecto?"* Si la respuesta es no, la hipótesis está mal redactada (es una opinión, no una hipótesis). Ajusten la redacción hasta que sea completamente falsable y medible.

SESIÓN 8

Trazando la Ruta: Objetivos y Preguntas

TEMA A TRATAR

Con el problema definido y la hipótesis planteada, el anteproyecto necesita un mapa de ejecución. Este mapa está constituido por las **Preguntas de Investigación** y los **Objetivos** (Generales y Específicos). Un error común en el ámbito de la tecnología es confundir un objetivo de investigación con una simple lista de tareas de programación. En esta sesión enseñaremos a estructurar objetivos metodológicos alineados a la matriz de congruencia.

Preguntas de Investigación

Las preguntas son el motor de la curiosidad académica. Deben derivarse directamente del planteamiento del problema. Debe existir una pregunta rectora (macro) y preguntas secundarias (micro) que abordarán los detalles técnicos, teóricos y operativos. Si la pregunta puede responderse con un "sí" o un "no", está mal formulada; debe requerir exploración y análisis.

Objetivo General y Objetivos Específicos

El **Objetivo General** es la meta máxima del proyecto; es la promesa final que el alumno le hace al sínodo. Debe iniciar con un verbo en infinitivo (ej. *Diseñar, Proponer, Evaluar, Desarrollar*) y debe encapsular el qué, el cómo y el para qué.

Los **Objetivos Específicos** son los hitos o escalones obligatorios para alcanzar el objetivo general. En proyectos de Ciencia de Datos, estos suelen seguir una secuencia metodológica clara: 1) Recopilar y estructurar datos, 2) Analizar o modelar, 3) Evaluar métricas de rendimiento, y 4) Desplegar o proponer la solución de negocio. Se prohíbe el uso de verbos operativos triviales (como "hacer", "buscar", "leer"); se exige el uso de verbos taxonómicos de alto nivel (como "sistematizar", "correlacionar", "optimizar").

La Matriz de Congruencia

Finalmente, se introduce la matriz de congruencia, el candado de seguridad del anteproyecto. En esta matriz, el alumno alinea en una tabla horizontal: El Problema, La Pregunta General, El Objetivo General y la Hipótesis. Si la lectura lineal de estos cuatro elementos tiene un hilo conductor lógico perfecto, el esqueleto del anteproyecto (evaluado con el 20% de la calificación) está listo para ser aprobado.

ESTUDIO DE CASO (INCIDENTE CRÍTICO)

El Proyecto Interminable y la Corrupción del Alcance

Un equipo de analistas junior fue contratado por una clínica privada para "mejorar el manejo de datos de pacientes". Como no redactaron objetivos específicos claros ni los validaron con los directivos, comenzaron a trabajar. Primero hicieron un dashboard, luego el cliente pidió predicciones de asistencia, luego un sistema de alertas por SMS.

Seis meses después, el proyecto colapsó. El equipo sufrió del fenómeno conocido como "Scope Creep" o *corrupción del alcance*. Al no tener un Objetivo General cerrado y Objetivos Específicos limitados, el proyecto se volvió un pozo sin fondo de requerimientos técnicos que no resolvían el problema original. En investigación y consultoría, los objetivos son el escudo legal y metodológico del científico de datos: definen exactamente cuándo el trabajo se considera terminado y exitoso.

INSTRUCCIONES PARA EL EJERCICIO

1. **Selección de Verbos (Taxonomía de Bloom):**

   Revisen la lista de verbos para investigación proporcionada por el docente. Seleccionen un verbo de "Alta Complejidad" (ej. *Evaluar, Diseñar, Formular*) para su Objetivo General. Seleccionen de 3 a 4 verbos de nivel medio/alto para sus Objetivos Específicos, asegurándose de que cubran las fases de recolección de datos, modelado y validación de negocio.

2. **Construcción de la Matriz de Congruencia:**

   En una hoja horizontal (apaisada) de Word, inserten una tabla con cuatro columnas: 1) Problema Central, 2) Pregunta Rectora, 3) Objetivo General, 4) Hipótesis/Supuesto. Llenen la tabla asegurando que los términos y el sujeto de estudio sean exactamente los mismos en las cuatro casillas para garantizar la congruencia metodológica.

3. **Integración del Esbozo - Parte 1 (Evaluación 20%):**

   Unifiquen todo el trabajo realizado desde la Sesión 4. Su documento deberá contener: Portada, Problematización (con las 4 etapas), Justificación, Viabilidad, Preguntas de Investigación, Objetivos (General y Específicos) e Hipótesis/Supuesto. Denle formato riguroso en APA 7ma edición y súbanlo a la plataforma bajo el título *"Esbozo_Anteproyecto_1_Apellidos"*. Esta entrega constituye el 20% de su calificación final del seminario.

SESIÓN 9

Paradigmas Metodológicos en la Ciencia de Datos

TEMA A TRATAR

Al llegar al Bloque C, el estudiante de séptimo semestre debe comprender que la Ciencia de Datos no es exclusivamente una disciplina numérica; es una intersección entre el análisis estadístico, el desarrollo de software y el entendimiento profundo de la conducta humana en los negocios. En esta sesión, se desglosará cómo justificar y seleccionar el **Enfoque Metodológico** adecuado: Cuantitativo, Cualitativo o Mixto.

El Enfoque Cuantitativo

Es el paradigma clásico y natural de la ciencia de datos. Se fundamenta en el positivismo: la realidad puede ser medida, clasificada y modelada. En este enfoque, el estudiante trabajará con variables numéricas o categóricas masivas, buscando correlaciones, aplicando estadística inferencial y entrenando algoritmos (Supervisados o No Supervisados). Su métrica de éxito está dictada por el rendimiento matemático: Precisión (*Accuracy*), *Recall*, *F1-Score* o Error Cuadrático Medio (*RMSE*). Este enfoque es obligatorio si el objetivo general es predecir ventas, clasificar imágenes o detectar fraudes financieros.

El Enfoque Cualitativo

Aunque subestimado en perfiles altamente técnicos, el enfoque cualitativo es crítico cuando el problema no es "cuánto" sino "por qué". Este paradigma busca comprender los fenómenos desde la perspectiva de los actores involucrados. En el ámbito de los datos, aplica en proyectos sobre Gobernanza de Datos, Ética de la Inteligencia Artificial, Auditoría de Sesgos (*Fairness in AI*) o diseño de arquitecturas de bases de datos donde las entrevistas a los usuarios de negocio dictarán la estructura del Data Warehouse.

El Enfoque Mixto

Representa el estándar de oro en la consultoría moderna de negocios. Combina el rigor estadístico del enfoque cuantitativo con la profundidad explicativa del cualitativo. Por ejemplo, un proyecto que desarrolla una red neuronal para analizar sentimientos en redes sociales (Cuantitativo/NLP), pero que triangula esos resultados con grupos focales (Cualitativo) para entender el origen sociocultural de las quejas de los clientes de una marca.

ESTUDIO DE CASO (INCIDENTE CRÍTICO)

El Modelo Perfecto que Nadie Usó

Una empresa de telecomunicaciones encargó a un equipo de científicos de datos la creación de un modelo predictivo para la fuga de clientes (*Churn Rate*). El equipo optó por un enfoque estrictamente **cuantitativo**. Desarrollaron un modelo *XGBoost* que lograba predecir con un 93% de precisión qué clientes cancelarían su plan el próximo mes.

A pesar del éxito matemático, la campaña de retención fracasó. El equipo de marketing no sabía qué hacer con la lista de clientes propensos a fugarse, pues el modelo no explicaba *por qué* se iban. Un consultor externo intervino y aplicó un enfoque **mixto**: complementó las predicciones con entrevistas cualitativas (*focus groups*) a una muestra de clientes que habían cancelado. Descubrieron que el problema no era el precio, sino una interfaz de aplicación móvil confusa. La matemática predijo el "quién"; la metodología mixta descubrió el "por qué".

INSTRUCCIONES PARA EL EJERCICIO

1. **Análisis de Congruencia del Enfoque:**

   Revisen la Hipótesis o Supuesto redactado en la Sesión 7. Respondan: ¿Mi hipótesis requiere medir volúmenes, porcentajes y frecuencias para ser comprobada, o requiere analizar percepciones, flujos de trabajo y regulaciones?

2. **Selección del Paradigma:**

   En su documento de trabajo, abran la sección "Metodología". Redacten un párrafo declarando si su investigación es Cuantitativa, Cualitativa o Mixta.

3. **Justificación Metodológica:**

   Redacten un segundo párrafo justificando la elección anterior basándose en la naturaleza de sus datos y su Objetivo General. Ejemplo: *"La presente investigación adopta un enfoque cuantitativo, dado que requiere el entrenamiento de un modelo de series de tiempo sobre un volumen de 500,000 registros históricos de ventas para predecir..."*

SESIÓN 10

Técnicas de Recolección de Información

TEMA A TRATAR

Una falacia común entre los estudiantes de Ciencia de Datos es asumir que la recolección de información se reduce a descargar un archivo CSV o un dataset ya limpio desde plataformas como Kaggle. En la realidad empresarial, los datos son difusos, fragmentados y a menudo atrapados en el conocimiento empírico del personal. Esta sesión aborda las técnicas formales e informáticas para extraer esa materia prima.

Técnicas Cuantitativas y Computacionales

Para proyectos predictivos, la "encuesta" tradicional ha evolucionado. Las técnicas de recolección primarias involucran la extracción automatizada de datos. Esto incluye el diseño de rutinas de *Web Scraping* para obtener información de mercados, el consumo de *APIs RESTful* para integrar datos financieros o meteorológicos en tiempo real, y el *Análisis de Bitácoras (Logs)* de servidores. El estudiante debe definir qué técnica informática empleará, con qué frecuencia (batch o streaming) y bajo qué esquema de almacenamiento.

Técnicas Cualitativas para Requisitos de Datos

Incluso el algoritmo más complejo requiere reglas de negocio previas. Aquí entran las técnicas cualitativas como la **Entrevista a Profundidad** o el **Grupo Focal**. Si un estudiante va a diseñar un modelo de predicción de precios para bienes raíces, no basta con los datos históricos; debe entrevistar a los gerentes de ventas (los expertos del dominio) para descubrir variables ocultas (como la percepción de seguridad del barrio) que deberán ser cuantificadas e integradas al modelo. La observación directa del flujo de trabajo es vital para no automatizar procesos ineficientes.

El diseño del "instrumento" (ya sea un cuestionario, una guía de entrevista estructurada o el código base del *spider* de scraping) debe estar documentado en el anteproyecto para garantizar que el método es replicable.

ESTUDIO DE CASO (INCIDENTE CRÍTICO)

El Algoritmo que Ignoró al Experto Humano

Un analista de datos junior recibió la tarea de crear un sistema de precios dinámicos para una cadena hotelera. Su técnica de recolección se limitó a descargar el historial de reservaciones de la base de datos central (técnica cuantitativa pasiva).

El modelo resultante comenzó a fijar precios excesivamente altos durante la temporada baja. El gerente general detuvo la implementación. ¿El error? El analista omitió utilizar una técnica de recolección complementaria: la **entrevista estructurada** con los directores de los hoteles. Si lo hubiera hecho, habría descubierto que, durante la temporada baja, los hoteles aplicaban descuentos corporativos masivos no documentados en la tarifa estándar de la base de datos, sino registrados en notas internas de Excel. Ignorar al experto humano corrompió la fuente de la verdad del algoritmo.

INSTRUCCIONES PARA EL EJERCICIO

1. **Mapeo de Fuentes:**

   Escriban una lista de todas las variables que su modelo o análisis requiere para funcionar. Al lado de cada variable, anoten la "Fuente" (ej. Base de datos SQL de la empresa, API de Twitter, Encuesta a clientes).

2. **Selección de Técnicas:**

   Clasifiquen cómo van a extraer esa información. ¿Usarán Extracción Computacional (APIs/ Scraping), Encuestas escalables o Entrevistas a Expertos del Dominio?

3. **Diseño Preliminar del Instrumento:**

   Si su técnica requiere intervención humana, redacten una guía de entrevista de 5 preguntas clave dirigidas al gerente o experto del negocio. Si su técnica es computacional, redacten un pseudocódigo o esquema lógico de los puntos finales (*endpoints*) o etiquetas HTML de donde extraerán el volumen de datos.

SESIÓN 11

Fundamentación Teórica y Aparato Crítico

TEMA A TRATAR

Todo desarrollo tecnológico descansa sobre los hombros de investigadores previos. La Fundamentación Teórica (o Marco Teórico) no es un relleno en el documento, sino la prueba fehaciente de que el estudiante conoce el "estado del arte" de la Inteligencia Artificial y los negocios. Además, el Aparato Crítico garantiza la probidad ética del trabajo.

Evitando el "Plagio Algorítmico"

En la era de la IA, el plagio ha mutado. Ya no se trata solo de copiar texto sin citar, sino de lo que institucionalmente llamamos *Plagio Algorítmico*. Esto ocurre cuando un estudiante descarga un modelo preentrenado (ej. de HuggingFace), una librería especializada o un dataset público, y lo presenta en su anteproyecto como creación propia, ignorando las licencias (MIT, Apache) y el crédito de los desarrolladores originales. El aparato crítico en Ciencia de Datos obliga a referenciar con formato APA no solo libros y artículos científicos, sino **repositorios de GitHub, conjuntos de datos y software especializado**.

Uso Estricto del Formato APA 7ma Edición

La búsqueda de información debe ser sistemática, priorizando repositorios indexados (Scopus, Google Scholar, IEEE Xplore, arXiv) por encima de blogs no verificados. Los alumnos aprenderán las reglas específicas de la APA 7ma edición para incrustar citas dentro de párrafos técnicos. Una fundamentación sólida deberá incluir: la teoría matemática subyacente del algoritmo elegido, el marco teórico de la métrica de negocio a impactar, y al menos dos estudios previos similares (estado del arte) para justificar la brecha que el estudiante pretende llenar.

ESTUDIO DE CASO (INCIDENTE CRÍTICO)

El Anteproyecto Rechazado por Omisión de Licencias

Un estudiante de excelencia presentó su anteproyecto proponiendo un revolucionario sistema de detección de fraudes mediante análisis de grafos. El comité revisor estaba impresionado por la complejidad técnica hasta que analizaron el "Aparato Crítico".

El documento no contenía ninguna referencia al dataset utilizado para el entrenamiento inicial, ni citaba a los autores del artículo original que propusieron esa arquitectura matemática específica en el portal *arXiv*. El estudiante alegó que "el código es abierto y de internet", incurriendo en una falta ética grave. En la ciencia de datos comercial y académica, el uso de herramientas *Open Source* requiere citación rigurosa. El proyecto fue suspendido hasta que el alumno reescribió el marco teórico dando crédito absoluto a la ingeniería de datos base, previniendo posibles violaciones de licencias de software libre.

INSTRUCCIONES PARA EL EJERCICIO

1. **Búsqueda en Repositorios Académicos:**

   Ingresen a Google Scholar, IEEE Xplore o arXiv. Localicen 5 artículos científicos (*papers*) publicados en los últimos 4 años que sean directamente relevantes para su problema de investigación.

2. **Fichaje y Referenciación (APA 7):**

   Abran un gestor bibliográfico (Mendeley, Zotero) o la herramienta de referencias de su procesador de texto. Creen las 5 referencias en formato estricto APA 7ma edición. Agreguen obligatoriamente una 6ta referencia que cite el dataset o la librería base de Machine Learning (ej. Scikit-Learn o un repositorio de GitHub) que utilizarán.

3. **Redacción de Síntesis:**

   Seleccionen el artículo más importante de los cinco. Redacten un párrafo de introducción a su Marco Teórico donde presenten las conclusiones de dicho artículo utilizando una cita narrativa o parentética correcta.

SESIÓN 12

Planeación y Tiempos de Ejecución

TEMA A TRATAR

Una excelente idea con una metodología robusta está destinada al fracaso si carece de una gestión de tiempos realista. En la culminación del Bloque C, el estudiante debe traducir la carga técnica y analítica de su proyecto en un Cronograma de Actividades medible y escalable, superando la planeación teórica para adentrarse en la gestión de proyectos (Project Management).

Integración CRISP-DM y Diagrama de Gantt

En el ámbito de la ciencia de datos, los cronogramas tradicionales a menudo no encajan con la realidad iterativa del análisis. Por ello, se instruye a los estudiantes a fusionar la representación visual de un *Diagrama de Gantt* con las fases estándar de la metodología **CRISP-DM (Cross-Industry Standard Process for Data Mining)**:

1. Entendimiento del Negocio (Business Understanding): Ya cubierto en el Bloque B del seminario.
2. Entendimiento de los Datos (Data Understanding): Tiempos asignados a la recolección, auditoría y análisis exploratorio inicial (EDA).
3. Preparación de los Datos (Data Preparation): El alumno debe prever que la limpieza, imputación de nulos y estandarización consumirá, típicamente, el 60% del tiempo operativo del proyecto en el siguiente semestre.
4. Modelado (Modeling): Selección, entrenamiento y ajuste de hiperparámetros de los algoritmos.
5. Evaluación (Evaluation): Pruebas de métricas, validación cruzada y contraste contra el objetivo de negocio.
6. Despliegue (Deployment): Generación del reporte final, integración en *dashboards* o puesta en producción básica.

Al asignar meses o semanas a estas fases, el estudiante demuestra al comité revisor que tiene un dominio maduro de los tiempos de desarrollo de una solución basada en Inteligencia Artificial.

ESTUDIO DE CASO (INCIDENTE CRÍTICO)

El Síndrome del 80% en Modelado

Una alumna planteó un proyecto de titulación para analizar la rotación de personal (HR Analytics) usando redes neuronales profundas. Al diseñar su cronograma, asignó un mes a la recolección de datos y tres meses completos a "entrenar el modelo".

Al llegar al octavo semestre, la realidad la golpeó. Los datos de Recursos Humanos venían en 5 sistemas diferentes, repletos de formatos incompatibles y registros nulos. Pasó tres meses en la fase de "Preparación de Datos" (Data Preparation). Como su cronograma no contemplaba esa holgura, se quedó sin tiempo para el entrenamiento avanzado. El sínodo le reprochó que su error no fue técnico, sino de gestión de proyectos: ignoró la máxima de la industria que dicta que la limpieza de datos consume el grueso del tiempo. Su planeación ingenua puso en riesgo su egreso.

INSTRUCCIONES PARA EL EJERCICIO

1. **Diseño del Cronograma CRISP-DM:**

   Abran Excel, Project o una herramienta en línea (como Miro o Asana). Creen un Diagrama de Gantt proyectado para el 8vo semestre (aproximadamente 16 semanas). Desglosen las actividades principales utilizando estrictamente las 6 fases de la metodología CRISP-DM.

2. **Asignación Realista de Holguras:**

   Basándose en el incidente crítico, asegúrense de asignar un porcentaje temporal lógico (otorgando al menos un 40% o 50% del bloque operativo a la preparación y limpieza de datos). Identifiquen la "ruta crítica" (tareas que, si se retrasan, retrasan todo el proyecto).

3. **Entrega del Esbozo - Parte 2 (Evaluación 15%):**

   Unifiquen los elementos de esta semana. A su documento original (Esbozo Parte 1), agréguenle las nuevas secciones: *Metodología (Enfoque, Técnicas, Aparato Crítico)* y *Cronograma de Actividades*. Exórtenlo en PDF y súbanlo a la plataforma bajo el título *"Esbozo_Anteproyecto_2_Apellidos"*. Esta entrega tiene un valor del 15% de su calificación.

SESIÓN 13

Diseño de Presentaciones de Alto Impacto

TEMA A TRATAR

Iniciando el Bloque D, el enfoque cambia del desarrollo metodológico a la **Comunicación Visual**. El mejor modelo algorítmico o la investigación más rigurosa fracasan si no pueden ser explicados a una audiencia técnica y de negocios simultáneamente. Esta sesión aborda el diseño de presentaciones efectivas aplicando el concepto de *Storytelling with Data* (Narrativa con datos).

Carga Cognitiva y Jerarquía Visual

Se instruirá a los estudiantes sobre los principios de diseño que evitan la sobrecarga cognitiva en las presentaciones académicas. Diapositivas saturadas de texto o gráficas complejas sin una anotación clara disminuyen la retención del jurado. El estudiante aprenderá a aplicar la "Jerarquía Visual", utilizando el contraste, el color y el espacio en blanco para guiar el ojo del sínodo hacia los hallazgos críticos de su problematización, justificación y metodología.

Recursos Digitales para la Defensa

La presentación no es un reflejo de texto de su documento; es un material de apoyo audiovisual. Se revisarán criterios específicos para el uso de herramientas institucionales y de vanguardia, promoviendo recursos dinámicos como infografías ejecutivas o videos cortos que sinteticen el problema, garantizando que el discurso no se exceda de los 10 minutos estipulados por la normativa de la materia.

ESTUDIO DE CASO (INCIDENTE CRÍTICO)

El Dashboard que Confundió al Directorio

Un equipo de analistas presentó los resultados de un modelo predictivo a la junta directiva de una empresa de retail. Su presentación consistía en 40 diapositivas repletas de matrices de confusión, curvas ROC y tablas SQL extraídas directamente de su entorno de desarrollo.

A los diez minutos, la junta directiva perdió el interés y rechazó el financiamiento para implementar el modelo. El incidente radicó en una falla de **comunicación visual**. Los analistas diseñaron la presentación para otros científicos de datos, no para los tomadores de decisiones. Si hubieran utilizado el *Storytelling with Data* (traduciendo la curva ROC a "Dinero ahorrado proyectado" y eliminando el código fuente de las diapositivas), el proyecto habría sido aprobado. La síntesis es la herramienta persuasiva más poderosa del científico de datos.

INSTRUCCIONES PARA EL EJERCICIO

1. **Creación del Guion Gráfico (Storyboard):**

   Utilizando papel y lápiz, o una herramienta de *wireframing* simple, esbocen 8 diapositivas (cuadros). A cada cuadro asígnenle un título (ej. "El Problema", "La Hipótesis", "Metodología", "Cronograma") y describan brevemente qué elemento visual (un ícono, una gráfica, una palabra clave) dominará esa diapositiva.

2. **Aplicación de la Regla del 6x6:**

   Abran su software de presentaciones. Creen la diapositiva correspondiente a su "Justificación". Apliquen la regla de no más de 6 viñetas y no más de 6 palabras por línea. Eliminen todo el texto innecesario y reemplácenlo con el discurso verbal que ustedes darán.

3. **Selección de Gráficos:**

   Identifiquen en su documento la métrica más importante de su caracterización del problema. Busquen la mejor representación gráfica para ella (gráfico de barras, dona, línea de tiempo) e insértenla en su presentación asegurando que el color institucional (Guinda UNRC) resalte el dato más alarmante.

SESIÓN 14

Taller de Revisión y Ajuste Documental

TEMA A TRATAR

Antes de la entrega final, es imperativo someter el anteproyecto a un escrutinio riguroso. Esta sesión funciona como un taller práctico de revisión cruzada (coevaluación) donde los estudiantes actúan como auditores metodológicos del trabajo de sus pares. El objetivo es pulir el documento de ocho cuartillas en formato PDF, garantizando su alineación milimétrica con la rúbrica institucional.

Criterios Finales y Rúbricas

Se repasarán los componentes obligatorios del documento final: 1) Carátula institucional, 2) Problematización, 3) Definición del problema, 4) Hipótesis o Supuesto, 5) Preguntas, 6) Objetivos (Generales y Específicos), 7) Metodología y Técnicas, 8) Cronograma de actividades, y 9) Aparato Crítico.

El formato es innegociable: Normas APA 7ma edición. Un científico de datos debe ser tan riguroso con la limpieza de su código como con la estructuración de sus informes formales. Se evaluará la coherencia interna mediante la Matriz de Congruencia desarrollada en sesiones anteriores, asegurando que el objetivo general ataque directamente la fricción planteada en la problematización.

ESTUDIO DE CASO (INCIDENTE CRÍTICO)

El Código Brillante y el Documento Rechazado

Un alumno diseñó un algoritmo de segmentación *K-Means* sumamente innovador para su proyecto. Dedicó el 95% del semestre a programar y solo el 5% a redactar el documento recepcional. Días antes del cierre, compiló sus notas rápidamente, omitió el formato APA, superó el límite de cuartillas y olvidó anexar el cronograma metodológico.

A pesar de la excelencia técnica de su código, el comité académico rechazó el anteproyecto. En el mundo corporativo y académico, el rigor formal no es un adorno; es el protocolo de aseguramiento de calidad. Un documento mal estructurado o que ignora las rúbricas establecidas refleja una falta de profesionalismo que ensombrece cualquier avance algorítmico.

INSTRUCCIONES PARA EL EJERCICIO

1. **Autoevaluación con Rúbrica:**

   Descarguen la rúbrica oficial de evaluación del Seminario I. Marquen en su propio documento (con comentarios al margen) el lugar exacto donde cumplen con cada uno de los 9 criterios institucionales obligatorios.

2. **Revisión de Pares (Auditoría Ciega):**

   Intercambien su documento PDF (máximo 8 cuartillas) con un compañero. Revisen el documento recibido enfocándose únicamente en dos aspectos: 1) ¿Las citas y la bibliografía cumplen estrictamente con APA 7ma edición? y 2) ¿El Objetivo General responde directamente a las Preguntas de Investigación? Anoten sus observaciones de mejora constructiva.

3. **Ajuste Final y Maquetación:**

   Realicen las correcciones señaladas por su compañero. Verifiquen que la carátula contenga sus datos correctos, que el archivo esté guardado en PDF para evitar saltos de formato y preparen el documento final para su carga en Google Classroom.

SESIÓN 15

Comunicación de Resultados

TEMA A TRATAR

Llegar al resultado correcto es solo la mitad del trabajo del científico de datos; la otra mitad es lograr que los tomadores de decisiones entiendan y confíen en ese resultado. Esta sesión está orientada al desarrollo de habilidades de comunicación oral y al ensayo del *Pitch* académico para la defensa del anteproyecto.

El Pitch de 10 Minutos

La normativa institucional es estricta: los alumnos cuentan con un máximo de 10 minutos para sintetizar meses de investigación ante una audiencia. Para lograr esto, se entrenará a los estudiantes en la técnica del *Elevator Pitch* aplicado a proyectos de datos: enganchar a la audiencia en los primeros 30 segundos (el problema), presentar la propuesta de valor metodológica a la mitad (hipótesis y enfoque), y cerrar contundentemente con el impacto y la viabilidad del cronograma.

Habilidades de Comunicación No Verbal

Se abordarán técnicas de control de la ansiedad, el uso del espacio físico (o el encuadre de cámara si es virtual), el tono de voz para mantener la atención del sínodo, y lo más importante: cómo enfrentar la sesión de Preguntas y Respuestas (Q&A). Se instruirá sobre cómo responder con solidez técnica y humildad académica frente a las observaciones de los sinodales.

ESTUDIO DE CASO (INCIDENTE CRÍTICO)

La Defensa Monótona que Perdió al Jurado

Durante una jornada de defensas de titulación, un estudiante proyectó su presentación y procedió a leer textualmente, dando la espalda al sínodo, cada uno de los párrafos que ya estaban escritos en su documento de tesis. Su tono de voz era plano y excedió el tiempo límite a pesar de las advertencias del moderador.

El sínodo detuvo la presentación al minuto 15. Aunque el documento del alumno era bueno, la falta de preparación para la defensa oral demostró incapacidad de síntesis y poco dominio del tema. Una defensa no es una sesión de lectura pública; es un ejercicio de persuasión y apropiación del conocimiento. Dominar la comunicación oral es fundamental para ascender a roles de liderazgo como "Lead Data Scientist".

INSTRUCCIONES PARA EL EJERCICIO

1. **Ensayo Cronometrado Individual:**

   Tomen su presentación visual (desarrollada en la Sesión 13). Pónganse de pie, enciendan el cronómetro de su teléfono y dicten su presentación completa. Deténganse cuando suene la alarma a los 9 minutos. Si no terminaron, ajusten y recorten el contenido de su guion.

2. **Simulacro en Micro-Grupos (Evaluación 15%):**

   Reúnanse en grupos de 4 personas. Cada alumno presentará su recurso digital (Infografía, Presentación o Video) ante el resto. Los tres compañeros fungirán como el sínodo, evaluando la postura, claridad y el uso del tiempo.

3. **Ronda de Preguntas (Q&A):**

   Al finalizar cada simulacro, el sínodo del grupo hará dos preguntas incisivas sobre la viabilidad o los datos del proyecto. El presentador deberá practicar la técnica de respuesta: "Escuchar, Validar la observación y Responder con evidencia de su metodología". El profesor evaluará esta síntesis para otorgar el 15% de la UCA.

SESIÓN 16

Defensa del Anteproyecto

TEMA A TRATAR

Esta es la sesión de clausura del Seminario de Titulación I. El proceso formativo ha culminado y da paso al ejercicio formal de evaluación académica. En esta sesión, los estudiantes ejecutarán la presentación final de su Anteproyecto Recepcional integrando todas las correcciones, habilidades y métricas desarrolladas a lo largo de los bloques anteriores.

Evaluación Final e Integración del Sínodo

El propósito de esta sesión es simular las condiciones de un examen profesional real. Para enriquecer el debate y la retroalimentación, se sugiere la participación de miembros de la academia (como el Dr. Victor Arellano, Dra. Yuliana Zarate, Dr. Mario Hugo Cuéllar o el Mtro. Alonso Jimenez) en calidad de sinodales invitados. Ellos evaluarán tanto la solidez del documento escrito en formato APA como la fluidez, seguridad y rigor técnico de la presentación audiovisual.

El Tránsito a Seminario de Titulación II

La defensa no marca el final del proyecto, sino la obtención de la "luz verde" institucional. Las observaciones recibidas por parte del jurado durante esta sesión deberán ser registradas cuidadosamente por el estudiante, ya que constituirán la primera tarea de ajuste para la fase de implementación y análisis de datos estadísticos que se llevará a cabo en el Seminario de Titulación II.

Nota sobre la Sesión de Clausura

Para esta sesión final, no se asigna un incidente crítico o texto maestro adicional. Todo el tiempo cronometrado de la clase está dedicado exclusivamente a las rondas de exposición de los estudiantes (10 minutos de presentación + 5 minutos de retroalimentación del sínodo por alumno).

INSTRUCCIONES PARA EL EJERCICIO

1. **Entrega del Documento Maestro (Evaluación 30%):**

   Previo al inicio de las presentaciones, asegúrense de haber cargado a la plataforma institucional el archivo PDF final de 8 cuartillas (Esbozo Final), aplicando las normas APA 7ma edición y que incluya los elementos metodológicos requeridos.

2. **Presentación Audiovisual:**

   Realicen su exposición frente al grupo y el jurado invitado. Muestren dominio del escenario, gestionen correctamente sus 10 minutos de tiempo y demuestren la justificación ética, técnica y social de su proyecto de Ciencia de Datos.

3. **Recepción de Retroalimentación:**

   Tomen nota activa de los comentarios, observaciones y áreas de mejora dictadas por los sinodales. La aceptación formal de su documento en esta sesión los habilita para continuar con el desarrollo de los algoritmos y la minería de datos en el próximo semestre.

ANEXO

Bibliografía Básica y de Consulta

El siguiente listado compila los 15 textos fundamentales, en formato APA 7ma edición, que sustentan la metodología de la investigación, el modelado de datos y el desarrollo de pensamiento complejo aplicados en este manual y en el diseño de anteproyectos en Ciencia de Datos para Negocios.

American Psychological Association. (2020). *Publication manual of the American Psychological Association* (7ma ed.). https://doi.org/10.1037/0000165-000

Baesens, B. (2014). *Analytics in a Big Data World: The Essential Guide to Data Science and its Applications*. Wiley.

Cairo, A. (2016). *The Truthful Art: Data, Charts, and Maps for Communication*. New Riders.

Creswell, J. W., & Creswell, J. D. (2018). *Research Design: Qualitative, Quantitative, and Mixed Methods Approaches* (5ta ed.). SAGE Publications.

Davenport, T. H. (2014). *Big Data @ Work: Dispelling the Myths, Uncovering the Opportunities*. Harvard Business Review Press.

Gómez, M., Galeano, C., & Jaramillo, D. (2015). El estado del arte: Una metodología de investigación. *Revista Colombiana de Ciencias Sociales, 6*(2), 423-442.

Hernández Sampieri, R., Fernández Collado, C., & Baptista Lucio, P. (2014). *Metodología de la investigación* (6ta ed.). McGraw-Hill.

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning: with Applications in R* (2da ed.). Springer.

Knaflic, C. N. (2015). *Storytelling with Data: A Data Visualization Guide for Business Professionals*. Wiley.

Mayer-Schönberger, C., & Cukier, K. (2013). *Big Data: A Revolution That Will Transform How We Live, Work, and Think*. Houghton Mifflin Harcourt.

McKinney, W. (2022). *Python for Data Analysis: Data Wrangling with pandas, NumPy, and Jupyter* (3ra ed.). O'Reilly Media.

O'Neil, C. (2016). *Weapons of Math Destruction: How Big Data Increases Inequality and Threatens Democracy*. Crown.

Provost, F., & Fawcett, T. (2013). *Data Science for Business: What you need to know about data mining and data-analytic thinking*. O'Reilly Media.

Schutt, R., & O'Neil, C. (2013). *Doing Data Science: Straight Talk from the Frontline*. O'Reilly Media.

Witten, I. H., Frank, E., Hall, M. A., & Pal, C. J. (2016). *Data Mining: Practical Machine Learning Tools and Techniques* (4ta ed.). Morgan Kaufmann.